

Parte 1 - Trabalho 2ª VAE - Estatística Computacional

João Pedro

2026-06-05

A PNAD Contínua (Pesquisa Nacional por Amstras de Domicílios Contínua) é a principal fonte de dados sobre o mercado de trabalho brasileiro. O objetivo desse trabalho é analisar estatísticas importantes a respeito dos dados da PNAD Contínua referentes ao quarto trimestre de 2025 no estado do Rio de Janeiro.

```
#carregando os pacotes  
library(PNADcIBGE)
```

```
## Warning: pacote 'PNADcIBGE' foi compilado no R versão 4.5.3
```

```
library(srvyr)
```

```
## Warning: pacote 'srvyr' foi compilado no R versão 4.5.3
```

```
##  
## Anexando pacote: 'srvyr'
```

```
## O seguinte objeto é mascarado por 'package:stats':  
##  
##      filter
```

```
library(dplyr)
```

```
## Warning: pacote 'dplyr' foi compilado no R versão 4.5.3
```

```
##  
## Anexando pacote: 'dplyr'
```

```
## Os seguintes objetos são mascarados por 'package:stats':  
##  
##      filter, lag
```

```
## Os seguintes objetos são mascarados por 'package:base':  
##  
##      intersect, setdiff, setequal, union
```

Após carregar os pacotes necessários, fiz o download da base de dados com as variáveis que utilizaria.

```
#salvando os dados referentes ao quarto trimestre de 2025 da PNAD
base <- get_pnadc(year = 2025, quarter = 4, vars = c("VD4020", "V2007", "V2009", "VD3005", "VD4001", "UF"))
#transformando em objeto de analise amostral
base <- as_survey(base)
```

Foram excluídas observações com rendimento igual a zero para evitar distorções na análise descritiva do rendimento e permitir melhor comparação entre os grupos estudados. Além disso, também foram retiradas as observações com valor NA para que os cálculos sejam possíveis e somente as observações sobre pessoas na força de trabalho foram selecionadas. A variável referente aos anos de estudo de cada pessoa estava salva como cadeia de caracteres. Para que fosse possível usá-la nos cálculos, precisei criar uma nova variável com valores do tipo inteiro referentes aos valores da variável original.

```
#retirando os NAs e os valores iguais a 0
base_isna <- base[!is.na(base$variables$VD4020) & base$variables$VD4020 != 0, ]
base_pea <- filter(base_isna, VD4001 == 'Pessoas na força de trabalho')
#recodificando categorias de escolaridade em anos numéricos de estudo
base_final <-
mutate(base_pea, anos.de.estudo = recode(VD3005, 'Sem instrução e menos de 1 ano de estudo' = 0,
'1 ano de estudo' = 1, '2 anos de estudo' = 2,
'3 anos de estudo' = 3, '4 anos de estudo' = 4,
'5 anos de estudo' = 5, '6 anos de estudo' = 6,
'7 anos de estudo' = 7, '8 anos de estudo' = 8,
'9 anos de estudo' = 9, '10 anos de estudo' = 10,
'11 anos de estudo' = 11, '12 anos de estudo' = 12,
'13 anos de estudo' = 13, '14 anos de estudo' = 14,
'15 anos de estudo' = 15, '16 anos ou mais de estudo' = 16))
```

```
#criando nova base apenas com os dados do rio de janeiro
base_rj <- filter(base_final, UF == "Rio de Janeiro")
```

Após filtrar a base para utilizar apenas os dados do Rio de Janeiro, foram realizadas as análises referentes a gênero e faixa etária.


Agora partimos para a exibição das estatísticas a respeito de cada tema (Rendimento x Gênero e Rendimento x Faixa Etária).

```
#numero de obs, media e desvio padrao por genero
base_rj %>%
  group_by(V2007) %>%
  summarise(
    n = n(),
    media_rendimento = mean(VD4020, na.rm = TRUE),
    desvio_padrao = sd(VD4020, na.rm = TRUE)
  )
```

```
## # A tibble: 2 × 4
##   V2007      n media_rendimento desvio_padrao
##   <fct> <int>          <dbl>          <dbl>
## 1 Homem  8426          4527.          8084.
## 2 Mulher  7112          3523.          5374.
```

Agora classificando por gênero vemos que a média de rendimento dos homens é aproximadamente 28% maior do que a das mulheres. Além disso, os homens apresentam também um maior desvio padrão, indicando maior dispersão.


```
#boxplot por genero
homem <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Homem"]
mulher <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Mulher"]
boxplot(
  homem,
  mulher,
  names = c("Homem", "Mulher"),
  main = "Rendimento por Gênero",
  ylab = "Rendimento"
)
```



no boxplot acima que o grupo masculino apresenta um maior número de valores extremos em comparação com o feminino. Imprimirei o mesmo boxplot mas sem os outliers para analisar melhor os quartis.

```
#boxplot por genero sem outliers
homem <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Homem"]
mulher <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Mulher"]
boxplot(
  homem,
  mulher,
  names = c("Homem", "Mulher"),
  main = "Rendimento por Gênero",
  ylab = "Rendimento",
  outline = FALSE
)
```

Rendimento por Gênero



outliers vemos que os homens realmente apresentam maior dispersão. As mulheres, por sua vez, apresentam menor dispersão e ainda por cima têm sua mediana abaixo dos 2.000, indicando uma concentração relevante de rendimentos abaixo de 2000.

```
#imprimindo a ANOVA
anova_genero <- aov(VD4020 ~ V2007, data = base_rj$variables)

summary(anova_genero)
```

```
##              Df    Sum Sq   Mean Sq F value Pr(>F)
## V2007          1 3.895e+09 3.895e+09   80.05 <2e-16 ***
## Residuals    15536 7.559e+11 4.865e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Foi realizada uma análise de variância (ANOVA) com o objetivo de verificar se existiam diferenças estatisticamente significativas entre os rendimentos médios dos gêneros. O teste apresentou valor de F elevado e p-valor inferior a 0,05, indicando evidência suficiente para rejeitar a hipótese nula de igualdade entre as médias. Dessa forma, conclui-se que há diferença estatisticamente significativa entre os rendimentos médios dos grupos analisados. Esse resultado está em concordância com a análise descritiva e com os boxplots, que já indicavam um rendimento maior do gênero masculino.

```
#criando grupos de acordo com a faixa etaria
base_rj <- base_rj %>%
  mutate(
    grupo_idade = ifelse(
      V2009 <= 25,
      "Até 25 anos",
      ifelse(
        V2009 <= 35,
        "26 a 35 anos",
        ifelse(
          V2009 <= 50,
          "36 a 50 anos",
          "Mais de 50 anos"
        )
      )
    )
  )
)
```

```
#ordenando as classes em ordem crescente para melhor visualização na tabela
base_rj$variables$grupo_idade <- factor(
  base_rj$variables$grupo_idade,
  levels = c(
    "Até 25 anos",
    "26 a 35 anos",
    "36 a 50 anos",
    "Mais de 50 anos"
  )
)
```

Após organizar as idades em grupos e armazená-los em ordem crescente, verifiquei o número de observações, média e desvio padrão de cada um.

```
#numero de observacoes, media e desvio padrao das faixas etarias
base_rj %>%
  group_by(grupo_idade) %>%
  summarise(
    n = n(),
    media_rendimento = mean(VD4020, na.rm = TRUE),
    desvio_padrao = sd(VD4020, na.rm = TRUE)
  )
```

```
## # A tibble: 4 × 4
##   grupo_idade      n media_rendimento desvio_padrao
##   <fct>         <int>         <dbl>         <dbl>
## 1 Até 25 anos    1665          1975.          2781.
## 2 26 a 35 anos   3222          3594.          5630.
## 3 36 a 50 anos   5784          4726.          8189.
## 4 Mais de 50 anos 4867          4314.          7114.
```

Pode-se notar uma certa semelhança entre os grupos de 36 a 50 anos e mais de 50, apesar do grupo de 36 a 50 apresentar média e desvio padrão relativamente superiores.

```
#boxplot das faixas etarias (largura e altura ajustadas)
ate25 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "Até 25 anos"]


de26a35 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "26 a 35 anos"]

de36a50 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "36 a 50 anos"]

mais50 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "Mais de 50 anos"]

boxplot(
  ate25,
  de26a35,
  de36a50,
  mais50,
  names = c("Até 25 anos", "26 a 35 anos", "36 a 50 anos", "50+ anos"),
  main = "Rendimento por Idade",
  ylab = "Rendimento"
)
```


Rendimento por Idade



No boxplot podemos ver que

os grupos de 36 a 50 e mais de 50 apresentam número de outliers parecido, sendo o grupo de 36 a 50 o que apresenta a observação de maior rendimento. Mais uma vez criarei outro boxplot sem outliers para melhor análise.

```
#boxplot das faixas etarias sem outliers (altura e largura ajustadas)
boxplot(
  ate25,
  de26a35,
  de36a50,
  mais50,
  names = c("Até 25 anos", "26 a 35 anos", "36 a 50 anos", "50+ anos"),
  main = "Rendimento por Idade",
  ylab = "Rendimento",
  outline = FALSE
)
```



parecidas entre os 3 últimos grupos, sendo que o grupo de 36 a 50 anos apresenta mediana e dispersão um pouco maiores do que os outros dois. Além disso, é importante destacar o quão concentrado está o grupo de até 25 anos, seu terceiro quartil está em torno de 2000, isso quer dizer que dentre as observações, 75% das pessoas com até 25 anos possuem renda de até R\$2.000,00.

```
#imprimindo a ANOVA
anova_idade <- aov(VD4020 ~ grupo_idade, data = base_rj$variables)

summary(anova_idade)
```

```
##              Df    Sum Sq  Mean Sq F value Pr(>F)
## grupo_idade    3 1.082e+10 3.606e+09   74.78 <2e-16 ***
## Residuals 15534 7.489e+11 4.821e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
TukeyHSD(anova_idade)
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = VD4020 ~ grupo_idade, data = base_rj$variables)
##
## $grupo_idade
##
```

	diff	lwr	upr	p adj
## 26 a 35 anos-Até 25 anos	1618.3733	1079.9192	2156.82744	0.0000000
## 36 a 50 anos-Até 25 anos	2750.8569	2254.6930	3247.02081	0.0000000
## Mais de 50 anos-Até 25 anos	2338.7367	1832.2329	2845.24050	0.0000000
## 36 a 50 anos-26 a 35 anos	1132.4836	740.3027	1524.66456	0.0000000
## Mais de 50 anos-26 a 35 anos	720.3634	315.1802	1125.54655	0.0000294
## Mais de 50 anos-36 a 50 anos	-412.1202	-759.1349	-65.10559	0.0122253

Após a ANOVA, foi aplicado o teste de comparações múltiplas de Tukey para identificar quais grupos etários diferiam entre si. Os resultados mostraram diferenças estatisticamente significativas entre todos os pares de grupos analisados ($p < 0,05$). A maior diferença observada ocorreu entre os grupos “Até 25 anos” e “36 a 50 anos”, cuja diferença média foi de aproximadamente R\$ 2.751. Embora os grupos “36 a 50 anos” e “Mais de 50 anos” apresentem médias relativamente próximas, o teste de Tukey também indicou diferença significativa entre eles ($p = 0,012$).