

Parte 2 - VAE2 - Est. Comp.

João Pedro

2026-06-10

```
#carregando os pacotes
library(PNADcIBGE)
```

```
## Warning: pacote 'PNADcIBGE' foi compilado no R versão 4.5.3
```

```
library(srvyr)
```

```
## Warning: pacote 'srvyr' foi compilado no R versão 4.5.3
```

```
##
## Anexando pacote: 'srvyr'
```

```
## O seguinte objeto é mascarado por 'package:stats':
##
##      filter
```

```
library(dplyr)
```

```
## Warning: pacote 'dplyr' foi compilado no R versão 4.5.3
```

```
##
## Anexando pacote: 'dplyr'
```

```
## Os seguintes objetos são mascarados por 'package:stats':
##
##      filter, lag
```

```
## Os seguintes objetos são mascarados por 'package:base':
##
##      intersect, setdiff, setequal, union
```

```
library(summarytools)
```

```
## Warning: pacote 'summarytools' foi compilado no R versão 4.5.3
```

```
library(lmtest)
```

```
## Warning: pacote 'lmtest' foi compilado no R versão 4.5.3
```

```
## Carregando pacotes exigidos: zoo
```

```
## Warning: pacote 'zoo' foi compilado no R versão 4.5.3
```

```
##  
## Anexando pacote: 'zoo'
```

```
## Os seguintes objetos são mascarados por 'package:base':  
##  
##      as.Date, as.Date.numeric
```

```
library(stargazer)
```

```
##  
## Please cite as:
```

```
## Hlavac, Marek (2022). stargazer: Well-Formatted Regression and Summary Statistics Tables.
```

```
## R package version 5.2.3. https://CRAN.R-project.org/package=stargazer
```

```
library(tseries)
```

```
## Warning: pacote 'tseries' foi compilado no R versão 4.5.3
```

```
## Registered S3 method overwritten by 'quantmod':  
##      method      from  
##      as.zoo.data.frame zoo
```

Após carregar os pacotes necessários, fiz o download da base de dados com as variáveis que utilizaria.

```
#salvando os dados referentes ao quarto trimestre de 2025 da PNAD  
base <- get_pnadc(year = 2025, quarter = 4, vars = c("VD4020", "V2007", "V2009", "VD3005", "VD4001", "U  
F"))  
#transformando em objeto de análise amostral  
base <- as_survey(base)
```

```
#retirando os NAs e os valores iguais a 0  
base_isna <- base[!is.na(base$variables$VD4020) & base$variables$VD4020 != 0, ]  
base_pea <- filter(base_isna, VD4001 == 'Pessoas na força de trabalho')  
#recodificando categorias de escolaridade em anos numéricos de estudo  
base_final <-  
mutate(base_pea, anos.de.estudo = recode(VD3005, 'Sem instrução e menos de 1 ano de estudo' = 0,  
'1 ano de estudo' = 1, '2 anos de estudo' = 2,  
'3 anos de estudo' = 3, '4 anos de estudo' = 4,  
'5 anos de estudo' = 5, '6 anos de estudo' = 6,  
'7 anos de estudo' = 7, '8 anos de estudo' = 8,  
'9 anos de estudo' = 9, '10 anos de estudo' = 10,  
'11 anos de estudo' = 11, '12 anos de estudo' = 12,  
'13 anos de estudo' = 13, '14 anos de estudo' = 14,  
'15 anos de estudo' = 15, '16 anos ou mais de estudo' = 16))
```

Foram excluídas observações com rendimento igual a zero para evitar distorções na análise descritiva do rendimento e permitir melhor comparação entre os grupos estudados. Além disso, também foram retiradas as observações com valor NA para que os cálculos sejam possíveis e somente as observações sobre pessoas na força de trabalho foram selecionadas. A variável referente aos anos de estudo de cada pessoa estava salva como cadeia de caracteres. Para que fosse possível usá-la nos cálculos, precisei criar uma nova variável com valores do tipo inteiro referentes aos valores da variável original.

```
#criando nova base apenas com os dados do rio de janeiro
base_rj <- filter(base_final, UF == "Rio de Janeiro")
```

Após filtrar a base para usar apenas os dados do Rio de Janeiro, criei uma nova variável que agrupa em classes a quantidade de anos de estudo que cada pessoa possui e as ordenei em ordem crescente para melhor visualização no gráfico.

```
#agrupando por grupos de acordo com a escolaridade
base_rj <- base_rj %>% mutate( grupo_estudo = ifelse( anos.de.estudo <=
9
,
"Até 9 anos"
, ifelse( anos.de.estudo <=
12
,
"10 a 12 anos"
,
"13 anos ou mais"
) ) )
#ordenando as classes em ordem crescente para melhor visualização na tabela
base_rj$variables$grupo_estudo <- factor( base_rj$variables$grupo_estudo, levels = c(
"Até 9 anos"
,
"10 a 12 anos"
,
"13 anos ou mais"
))
```

```
classificar = function(vetor, limite1) {

  ifelse(vetor < limite1,
        "Abaixo da média",
        "Acima da média")
}
media_rendimento = mean(base_rj$variables$VD4020)
base_rj$variables$FAIXA_RENDA = classificar(base_rj$variables$VD4020, media_rendimento)
```

Criei função chamada classificar para agrupar as rendas em “acima da média” e “abaixo da média”.

```
renda = base_rj$variables$FAIXA_RENDA
estudo = base_rj$variables$grupo_estudo
ctable(
x = renda,
y = estudo, chisq = TRUE)
```

```
## Cross-Tabulation, Row Proportions
## renda * estudo
##
##
## -----
##          estudo      Até 9 anos      10 a 12 anos      13 anos ou mais      Total
##      renda
##  Abaixo da média      3299 (27.9%)      5676 (48.0%)      2862 (24.2%)      11837 (100.0%)
##    Acima da média       166 ( 4.5%)       759 (20.5%)      2776 (75.0%)       3701 (100.0%)
##          Total      3465 (22.3%)      6435 (41.4%)      5638 (36.3%)      15538 (100.0%)
## -----
##
## -----
## Chi.squared   df   p.value
## -----
##    3211.593     2       0
## -----
```


A tabela de contingência e o teste qui-quadrado fornecem evidências estatísticas suficientemente fortes para rejeitar a hipótese de independência entre as variáveis Faixa de Renda e Faixa de Escolaridade, devido ao baixíssimo p-valor do teste, aproximado para zero pelo próprio R.

```
#criando o modelo linear que envolve renda e anos de estudo
renda_esc = lm(data = base_rj$variables, formula = VD4020 ~ anos.de.estudo)
summary(renda_esc)
```

```
##
## Call:
## lm(formula = VD4020 ~ anos.de.estudo, data = base_rj$variables)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6270  -2611  -1329    680  293680
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -2442.56    181.44  -13.46  <2e-16 ***
## anos.de.estudo   547.65     14.58   37.56  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6696 on 15536 degrees of freedom
## Multiple R-squared:  0.08326,    Adjusted R-squared:  0.0832
## F-statistic: 1411 on 1 and 15536 DF,  p-value: < 2.2e-16
```

O modelo de regressão estimado apresentou intercepto igual a -2442,56 e uma inclinação igual a 547,65. Ou seja, um ano a mais de escolaridade aumenta o valor esperado para a renda em 547,65. Uma pessoa com 9 anos de escolaridade possui uma renda esperada de $-2442,56 + 547,65 \times 9$, aproximadamente 2486,29 reais.


```
#resíduos da regressao (decidi exibir também o gráfico com o eixo y limitado para melhor visualização)
res = residuals(renda_esc)
plot(fitted(renda_esc), res)
abline(h = 0, col = "red")
```



```
res <- residuals(renda_esc)

plot(fitted(renda_esc),
     res,
     ylim = c(-10000, 50000))

abline(h = 0, col = "red")
```




```
bptest(renda_esc)
```

```
##  
## studentized Breusch-Pagan test  
##  
## data: renda_esc  
## BP = 27.748, df = 1, p-value = 1.382e-07
```

A dispersão crescente dos pontos no gráfico dos resíduos já indicava que muito provavelmente os resíduos não possuem variância constante. Foi implementado o teste de Breusch-Pagan que evidenciou a heterocedasticidade dos resíduos devido ao baixíssimo p-valor (podemos rejeitar H_0 para os níveis usuais de significância).


```
hist(res, main = "Histograma dos resíduos")
```

Histograma dos resíduos



```
qqnorm(res)  
qqline(res, col = "red")
```

Normal Q-Q Plot




```
jarque.bera.test(res)
```

```
##  
##  Jarque Bera Test  
##  
## data:  res  
## X-squared = 89075302, df = 2, p-value < 2.2e-16
```

Quanto à normalidade dos resíduos, o histograma já evidencia uma forma bastante diferente da distribuição normal, além de pontos muito dispersos em relação à reta do gráfico Q-Q Plot. Utilizei o teste de normalidade de Jarque-Bera, que retornou um p-valor extremamente baixo, permitindo rejeitar a hipótese de normalidade dos resíduos para os níveis usuais de significância.

```
plot(res, type = "l")  
abline(h = 0, col = "red")
```



```
dwtest(renda_esc)
```

```
##  
##  Durbin-Watson test  
##  
## data:  renda_esc  
## DW = 1.4844, p-value < 2.2e-16  
## alternative hypothesis: true autocorrelation is greater than 0
```

O gráfico dos resíduos em função da ordem das observações sugere a existência de agrupamentos de resíduos com magnitudes semelhantes, indicando possível dependência entre eles. Para confirmar essa evidência, foi aplicado o teste de Durbin-Watson, obtendo-se estatística DW = 1,4844 e p-valor inferior a $2,2 \times 10^{-16}$. Assim, ao nível de significância de

5%, rejeita-se a hipótese de ausência de autocorrelação, concluindo-se que há evidências de autocorrelação positiva entre os resíduos do modelo.