

Parte 3 - VAE2 - Est. Comp.

João Pedro

2026-06-18

```
#carregando os pacotes  
library(PNADcIBGE)
```

```
## Warning: pacote 'PNADcIBGE' foi compilado no R versão 4.6.1
```

```
library(srvyr)
```

```
## Warning: pacote 'srvyr' foi compilado no R versão 4.6.1
```

```
##  
## Anexando pacote: 'srvyr'
```

```
## O seguinte objeto é mascarado por 'package:stats':  
##  
##      filter
```

```
library(dplyr)
```

```
## Warning: pacote 'dplyr' foi compilado no R versão 4.6.1
```

```
##  
## Anexando pacote: 'dplyr'
```

```
## Os seguintes objetos são mascarados por 'package:stats':  
##  
##      filter, lag
```

```
## Os seguintes objetos são mascarados por 'package:base':  
##  
##      intersect, setdiff, setequal, union
```

```
library(summarytools)
```

```
## Warning: pacote 'summarytools' foi compilado no R versão 4.6.1
```

```
library(lmtest)
```

```
## Warning: pacote 'lmtest' foi compilado no R versão 4.6.1
```

```
## Carregando pacotes exigidos: zoo
```

```
## Warning: pacote 'zoo' foi compilado no R versão 4.6.1
```

```
##  
## Anexando pacote: 'zoo'
```

```
## Os seguintes objetos são mascarados por 'package:base':  
##  
##      as.Date, as.Date.numeric
```

```
library(stargazer)
```

```
##  
## Please cite as:
```

```
## Hlavac, Marek (2022). stargazer: Well-Formatted Regression and Summary Statistics Tables.
```

```
## R package version 5.2.3. https://CRAN.R-project.org/package=stargazer
```

```
library(tseries)
```

```
## Warning: pacote 'tseries' foi compilado no R versão 4.6.1
```

```
## Registered S3 method overwritten by 'quantmod':  
##      method      from  
##      as.zoo.data.frame zoo
```

Após carregar os pacotes necessários, fiz o download da base de dados com as variáveis que utilizaria.

```
#salvando os dados referentes ao quarto trimestre de 2025 da PNAD  
base <- get_pnadc(year = 2025, quarter = 4, vars = c("VD4020", "V2007", "V2009", "VD3005", "V  
D4001", "UF"))  
#transformando em objeto de analise amostral  
base <- as_survey(base)
```

```
#retirando os NAs e os valores iguais a 0
base_isna <- base[!is.na(base$variables$VD4020) & base$variables$VD4020 != 0, ]
base_pea <- filter(base_isna, VD4001 == 'Pessoas na força de trabalho')
#recodificando categorias de escolaridade em anos numéricos de estudo
base_final <-
mutate(base_pea, anos.de.estudo = recode(VD3005, 'Sem instrução e menos de 1 ano de estudo' =
0,
'1 ano de estudo' = 1, '2 anos de estudo' = 2,
'3 anos de estudo' = 3, '4 anos de estudo' = 4,
'5 anos de estudo' = 5, '6 anos de estudo' = 6,
'7 anos de estudo' = 7, '8 anos de estudo' = 8,
'9 anos de estudo' = 9, '10 anos de estudo' = 10,
'11 anos de estudo' = 11, '12 anos de estudo' = 12,
'13 anos de estudo' = 13, '14 anos de estudo' = 14,
'15 anos de estudo' = 15, '16 anos ou mais de estudo' = 16))
```

Foram excluídas observações com rendimento igual a zero para evitar distorções na análise descritiva do rendimento e permitir melhor comparação entre os grupos estudados. Além disso, também foram retiradas as observações com valor NA para que os cálculos sejam possíveis e somente as observações sobre pessoas na força de trabalho foram selecionadas. A variável referente aos anos de estudo de cada pessoa estava salva como cadeia de caracteres. Para que fosse possível usá-la nos cálculos, precisei criar uma nova variável com valores do tipo inteiro referentes aos valores da variável original.

```
#criando nova base apenas com os dados do rio de janeiro
base_rj <- filter(base_final, UF == "Rio de Janeiro")
```

```
#criando o modelo linear que envolve log da renda e anos de estudo
log_renda_esc = lm(data = base_rj$variables, formula = log(VD4020) ~ anos.de.estudo)
summary(log_renda_esc)
```

```
##
## Call:
## lm(formula = log(VD4020) ~ anos.de.estudo, data = base_rj$variables)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.0694 -0.5068 -0.0232  0.4621  4.4891
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   6.452011   0.022082  292.19  <2e-16 ***
## anos.de.estudo 0.114994   0.001774   64.81  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8149 on 15536 degrees of freedom
## Multiple R-squared:  0.2128, Adjusted R-squared:  0.2128
## F-statistic: 4200 on 1 and 15536 DF, p-value: < 2.2e-16
```

Para contornar os problemas de heterocedasticidade e não normalidade observados na parte 2, reestimei o modelo aplicando uma transformação logarítmica à variável Renda. Em modelos log-lineares, o coeficiente associado à variável explicativa pode ser interpretado aproximadamente em termos percentuais. Como o

coeficiente estimado para a variável anos de estudo foi igual a 0,115, conclui-se que um ano adicional de escolaridade está associado a um aumento aproximado de 11,5% no rendimento esperado.

```
#resíduos da regressão com log
res = residuals(log_renda_esc)
plot(fitted(log_renda_esc), res)
abline(h = 0, col = "red")
```




gráfico dos resíduos apresenta uma dispersão mais uniforme em torno de zero quando comparado ao modelo da parte 2, indicando uma melhora na adequação do modelo após a transformação logarítmica.


```
bptest(log_renda_esc)
```

```
##
## studentized Breusch-Pagan test
##
## data: log_renda_esc
## BP = 31.522, df = 1, p-value = 1.972e-08
```

No caso da heterocedasticidade, a transformação logarítmica não eliminou o problema. O teste de Breusch-Pagan continuou apresentando p-valor inferior a $2,2 \times 10^{-16}$, de modo que seguimos rejeitando a hipótese de homocedasticidade dos resíduos.


```
hist(res, main = "Histograma dos resíduos")
```

Histograma dos resíduos



```
qqnorm(res)  
qqline(res, col = "red")
```

Normal Q-Q Plot




```
jarque.bera.test(res)
```

```
##
##  Jarque Bera Test
##
## data:  res
## X-squared = 1917.9, df = 2, p-value < 2.2e-16
```

Apesar de uma melhora visual nos gráficos usados para investigar normalidade dos resíduos, o teste de Jarque-Bera ainda retorna um baixíssimo p-valor, suficiente para rejeitarmos a hipótese de normalidade aos níveis usuais de confiança. Entretanto, o valor da estatística de Jarque-Bera (X-squared) caiu de forma considerável de 89075302 na parte 2 para 1917,9 agora na parte 3, o que mostra que realmente houve uma melhora após a transformação.

```
plot(res, type = "l")
abline(h = 0, col = "red")
```



```
dwtest(log_renda_esc)
```

```
##
##  Durbin-Watson test
##
## data:  log_renda_esc
## DW = 1.5736, p-value < 2.2e-16
## alternative hypothesis: true autocorrelation is greater than 0
```

O gráfico dos resíduos em função da ordem das observações mostra que os erros oscilam em torno de zero, porém apresenta alguns agrupamentos de resíduos com magnitudes semelhantes, sugerindo possível dependência entre observações consecutivas. Para verificar essa hipótese, foi aplicado o teste de Durbin-Watson, que apresentou estatística DW = 1,55 e p-valor inferior a $2,2 \times 10^{-16}$. Assim, rejeita-se a hipótese de ausência de autocorrelação, concluindo que há evidências de autocorrelação positiva entre os resíduos.

As conclusões das partes 2 e 3 são consistentes com os resultados obtidos no trabalho 1. Os box-plots e a ANOVA já indicavam que maiores níveis de escolaridade estão associados a maiores rendimentos. A regressão linear confirmou essa relação positiva entre anos de estudo e renda. A transformação logarítmica utilizada na parte 3 melhorou a distribuição dos resíduos. Dessa forma, todas as análises realizadas apontam para a existência de uma relação positiva entre escolaridade e rendimento.

```
multipla = lm(log(VD4020) ~ anos.de.estudo + V2009 + V2007,
  data = base_rj$variables)
summary(multipla)
```

```
##
## Call:
## lm(formula = log(VD4020) ~ anos.de.estudo + V2009 + V2007, data = base_rj$variables)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.3381 -0.4392 -0.0301  0.4212  4.5396
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.9169183   0.0318435  185.81  <2e-16 ***
## anos.de.estudo 0.1302854   0.0017361   75.05  <2e-16 ***
## V2009          0.0121695   0.0004639   26.23  <2e-16 ***
## V2007Mulher   -0.3800637   0.0126317  -30.09  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7766 on 15534 degrees of freedom
## Multiple R-squared:  0.2851, Adjusted R-squared:  0.285
## F-statistic: 2065 on 3 and 15534 DF,  p-value: < 2.2e-16
```

```
stargazer(log_renda_esc, multipla,
  type = "text",
  title = "Determinantes do Log do Rendimento",
  dep.var.labels = "Log do rendimento",
  column.labels = c("Modelo simples", "Modelo múltiplo"),
  covariate.labels = c("Anos de estudo",
    "Idade",
    "Mulher"),
  digits = 3)
```

```
##
## Determinantes do Log do Rendimento
## =====
##                               Dependent variable:
##                               -----
##                               Log do rendimento
##                               Modelo simples      Modelo múltiplo
##                               (1)                (2)
## -----
## Anos de estudo                0.115***          0.130***
##                               (0.002)           (0.002)
##
## Idade                        0.012***
##                               (0.0005)
##
## Mulher                       -0.380***
##                               (0.013)
##
## Constant                     6.452***          5.917***
##                               (0.022)           (0.032)
##
## -----
## Observations                 15,538            15,538
## R2                          0.213              0.285
## Adjusted R2                 0.213              0.285
## Residual Std. Error         0.815 (df = 15536)    0.777 (df = 15534)
## F Statistic                 4,200.400*** (df = 1; 15536) 2,064.971*** (df = 3; 15534)
## =====
## Note:                        *p<0.1; **p<0.05; ***p<0.01
```

Após criar o modelo de regressão múltipla e compará-lo com o modelo simples, observa-se uma diferença entre os coeficientes associados à escolaridade. No modelo simples, um ano adicional de estudo está associado a um aumento aproximado de 11,5% no rendimento esperado. Já no modelo múltiplo, mantendo idade e gênero constantes, esse aumento passa para aproximadamente 13%. Além disso, a idade também se mostrou relevante, de modo que um ano adicional de idade está associado a um aumento aproximado de 1,2% no rendimento esperado. Por fim, o coeficiente associado à variável Mulher indica que, mantendo as demais variáveis constantes, mulheres apresentam rendimento esperado menor do que homens com mesma escolaridade e idade.