

Trabalho 1ª VAE - Estatística Computacional

João Pedro

2026-04-24

A PNAD Contínua (Pesquisa Nacional por Amstras de Domicílios Contínua) é a principal fonte de dados sobre o mercado de trabalho brasileiro. O objetivo desse trabalho é analisar estatísticas importantes a respeito dos dados da PNAD Contínua referentes ao quarto trimestre de 2025 no estado do Rio de Janeiro.

```
#carregando os pacotes  
library(PNADcIBGE)
```

```
## Warning: pacote 'PNADcIBGE' foi compilado no R versão 4.5.3
```

```
library(srvyr)
```

```
## Warning: pacote 'srvyr' foi compilado no R versão 4.5.3
```

```
##  
## Anexando pacote: 'srvyr'
```

```
## O seguinte objeto é mascarado por 'package:stats':  
##  
##      filter
```

```
library(dplyr)
```

```
## Warning: pacote 'dplyr' foi compilado no R versão 4.5.3
```

```
##  
## Anexando pacote: 'dplyr'
```

```
## Os seguintes objetos são mascarados por 'package:stats':  
##  
##      filter, lag
```

```
## Os seguintes objetos são mascarados por 'package:base':  
##  
##      intersect, setdiff, setequal, union
```

Após carregar os pacotes necessários, fiz o download da base de dados com as variáveis que utilizaria.

```
#salvando os dados referentes ao quarto trimestre de 2025 da PNAD  
base <- get_pnadc(year = 2025, quarter = 4, vars = c("VD4020", "V2007", "V2009", "VD3005", "VD4001", "UF"))  
#transformando em objeto de analise amostral  
base <- as_survey(base)
```

Foram excluídas observações com rendimento igual a zero para evitar distorções na análise descritiva do rendimento e permitir melhor comparação entre os grupos estudados. Além disso, também foram retiradas as observações com valor NA para que os cálculos sejam possíveis e somente as observações sobre pessoas na força de trabalho foram selecionadas. A variável referente aos anos de estudo de cada pessoa estava salva como cadeia de caracteres. Para que fosse possível usá-la nos cálculos, precisei criar uma nova variável com valores do tipo inteiro referentes aos valores da variável original.

```
#retirando os NAs e os valores iguais a 0
base_isna <- base[!is.na(base$variables$VD4020) & base$variables$VD4020 != 0, ]
base_pea <- filter(base_isna, VD4001 == 'Pessoas na força de trabalho')
#recodificando categorias de escolaridade em anos numéricos de estudo
base_final <-
mutate(base_pea, anos.de.estudo = recode(VD3005, 'Sem instrução e menos de 1 ano de estudo' = 0,
'1 ano de estudo' = 1, '2 anos de estudo' = 2,
'3 anos de estudo' = 3, '4 anos de estudo' = 4,
'5 anos de estudo' = 5, '6 anos de estudo' = 6,
'7 anos de estudo' = 7, '8 anos de estudo' = 8,
'9 anos de estudo' = 9, '10 anos de estudo' = 10,
'11 anos de estudo' = 11, '12 anos de estudo' = 12,
'13 anos de estudo' = 13, '14 anos de estudo' = 14,
'15 anos de estudo' = 15, '16 anos ou mais de estudo' = 16))
```

```
#criando nova base apenas com os dados do rio de janeiro
base_rj <- filter(base_final, UF == "Rio de Janeiro")
```

Após filtrar a base para usar apenas os dados do Rio de Janeiro, criei uma nova variável que agrupa em classes a quantidade de anos de estudo que cada pessoa possui e as ordenei em ordem crescente para melhor visualização no gráfico.

```
#agrupando por grupos de acordo com a escolaridade
base_rj <- base_rj %>%
  mutate(
    grupo_estudo = ifelse(
      anos.de.estudo <= 9,
      "Até 9 anos",
      ifelse(
        anos.de.estudo <= 12,
        "10 a 12 anos",
        "13 anos ou mais"
      )
    )
  )
```

```
#ordenando as classes em ordem crescente para melhor visualização na tabela
base_rj$variables$grupo_estudo <- factor(
  base_rj$variables$grupo_estudo,
  levels = c(
    "Até 9 anos",
    "10 a 12 anos",
    "13 anos ou mais"
  )
)
```

Agora partimos para a exibição do número total de observações, média e desvio padrão do rendimento.

```
#exibindo o numero de observacoes, media e desvio padrao
base_rj %>%
  group_by(grupo_estudo) %>%
  summarise(
    n = n(),
    media_rendimento = mean(VD4020, na.rm = TRUE),
    desvio_padrao = sd(VD4020, na.rm = TRUE)
  )
```

```
## # A tibble: 3 × 4
##   grupo_estudo      n media_rendimento desvio_padrao
##   <fct>          <int>          <dbl>          <dbl>
## 1 Até 9 anos      3465          1891.          1881.
## 2 10 a 12 anos    6435          2590.          3694.
## 3 13 anos ou mais 5638          7091.         10123.
```

Os números mostram uma diferença grande entre o grupo com até 9 anos de estudo em comparação com o grupo com 13 ou mais. O grupo com 10 a 12 anos mostrou uma média aproximadamente 37% maior que o grupo de até 9, uma diferença considerável. Além disso, o grupo com 13 anos ou mais apresenta desvio padrão maior que 10 mil, indicando alta dispersão dos dados, o que pode estar associado à presença de valores extremos.


```
#criando o boxplot de cada grupo de escolaridade
ate9 <- base_rj$variables$VD4020[base_rj$variables$grupo_estudo == "Até 9 anos"]

de10a12 <- base_rj$variables$VD4020[base_rj$variables$grupo_estudo == "10 a 12 anos"]

mais13 <- base_rj$variables$VD4020[base_rj$variables$grupo_estudo == "13 anos ou mais"]

boxplot(
  ate9,
  de10a12,
  mais13,
  names = c("Até 9 anos", "10 a 12 anos", "13+ anos"),
  main = "Rendimento por Escolaridade",
  ylab = "Rendimento"
)
```


Rendimento por Escolaridade



confirma a presença de um número considerável de outliers, sendo o grupo com 13 ou mais anos o grupo que aparenta possuir mais valores extremos. São tantos que acabam dificultando a visualização dos quartis. Por isso, abaixo vou imprimir o mesmo boxplot mas sem os outliers.

```
#o mesmo boxplot, mas sem os outliers para uma melhor visualizacao
boxplot(
  ate9,
  de10a12,
  mais13,
  names = c("Até 9 anos", "10 a 12 anos", "13+ anos"),
  main = "Rendimento por Escolaridade",
  ylab = "Rendimento",
  outline = FALSE
)
```

Rendimento por Escolaridade



outliers, podemos analisar melhor o boxplot. De início já observamos que o grupo com 13 anos ou mais apresenta uma dispersão bem maior do que os demais grupos. Além disso, o grupo com até 9 anos apresenta baixíssima amplitude interquartílica, muito provavelmente devido ao fato de grande número de pessoas que recebe um salário mínimo.

```
#imprimindo a ANOVA
anova_anosestudo <- aov(VD4020 ~ grupo_estudo, data = base_rj$variables)

summary(anova_anosestudo)
```

```
##              Df    Sum Sq  Mean Sq F value Pr(>F)
## grupo_estudo    2 8.201e+10 4.100e+10   939.9 <2e-16 ***
## Residuals     15535 6.777e+11 4.363e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Foi realizada uma análise de variância (ANOVA) com o objetivo de verificar se existiam diferenças estatisticamente significativas entre os rendimentos médios dos grupos de escolaridade. O teste apresentou valor de F elevado e p-valor inferior a 0,05, indicando evidência suficiente para rejeitar a hipótese nula de igualdade entre as médias. Dessa forma, conclui-se que há diferença estatisticamente significativa entre os rendimentos médios dos grupos analisados. Esse resultado está em concordância com a análise descritiva e com os boxplots, que já indicavam aumento do rendimento com o nível de escolaridade.

```
#numero de obs, media e desvio padrao por genero
base_rj %>%
  group_by(V2007) %>%
  summarise(
    n = n(),
    media_rendimento = mean(VD4020, na.rm = TRUE),
    desvio_padrao = sd(VD4020, na.rm = TRUE)
  )
```

```
## # A tibble: 2 × 4
##   V2007      n media_rendimento desvio_padrao
##   <fct> <int>         <dbl>         <dbl>
## 1 Homem  8426          4527.          8084.
## 2 Mulher 7112          3523.          5374.
```


Agora classificando por gênero vemos que a média de rendimento dos homens é aproximadamente 28% maior do que a das mulheres. Além disso, os homens apresentam também um maior desvio padrão, indicando maior dispersão.

```
#boxplot por genero
homem <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Homem"]
mulher <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Mulher"]
boxplot(
  homem,
  mulher,
  names = c("Homem", "Mulher"),
  main = "Rendimento por Gênero",
  ylab = "Rendimento"
)
```



no boxplot acima que o grupo masculino apresenta um maior número de valores extremos em comparação com o feminino. Imprimirei o mesmo boxplot mas sem os outliers para analisar melhor os quartis.

```
#boxplot por genero sem outliers
homem <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Homem"]
mulher <- base_rj$variables$VD4020[base_rj$variables$V2007 == "Mulher"]
boxplot(
  homem,
  mulher,
  names = c("Homem", "Mulher"),
  main = "Rendimento por Gênero",
  ylab = "Rendimento",
  outline = FALSE
)
```



outliers vemos que os homens realmente apresentam maior dispersão. As mulheres, por sua vez, apresentam menor dispersão e ainda por cima têm sua mediana abaixo dos 2.000, indicando uma concentração relevante de rendimentos abaixo de 2000.

```
#imprimindo a ANOVA
anova_genero <- aov(VD4020 ~ V2007, data = base_rj$variables)

summary(anova_genero)
```

```
##              Df    Sum Sq   Mean Sq F value Pr(>F)
## V2007          1 3.895e+09 3.895e+09   80.05 <2e-16 ***
## Residuals    15536 7.559e+11 4.865e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Foi realizada uma análise de variância (ANOVA) com o objetivo de verificar se existiam diferenças estatisticamente significativas entre os rendimentos médios dos gêneros. O teste apresentou valor de F elevado e p-valor inferior a 0,05, indicando evidência suficiente para rejeitar a hipótese nula de igualdade entre as médias. Dessa forma, conclui-se que há

diferença estatisticamente significativa entre os rendimentos médios dos grupos analisados. Esse resultado está em concordância com a análise descritiva e com os boxplots, que já indicavam um rendimento maior do gênero masculino.

```
#criando grupos de acordo com a faixa etaria
base_rj <- base_rj %>%
  mutate(
    grupo_idade = ifelse(
      V2009 <= 25,
      "Até 25 anos",
      ifelse(
        V2009 <= 35,
        "26 a 35 anos",
        ifelse(
          V2009 <= 50,
          "36 a 50 anos",
          "Mais de 50 anos"
        )
      )
    )
  )
```

```
#ordenando as classes em ordem crescente para melhor visualização na tabela
base_rj$variables$grupo_idade <- factor(
  base_rj$variables$grupo_idade,
  levels = c(
    "Até 25 anos",
    "26 a 35 anos",
    "36 a 50 anos",
    "Mais de 50 anos"
  )
)
```

Após organizar as idades em grupos e armazená-los em ordem crescente, verifiquei o número de observações, média e desvio padrão de cada um.

```
#numero de observacoes, media e desvio padrao das faixas etarias
base_rj %>%
  group_by(grupo_idade) %>%
  summarise(
    n = n(),
    media_rendimento = mean(VD4020, na.rm = TRUE),
    desvio_padrao = sd(VD4020, na.rm = TRUE)
  )
```

```
## # A tibble: 4 × 4
##   grupo_idade      n media_rendimento desvio_padrao
##   <fct>         <int>         <dbl>         <dbl>
## 1 Até 25 anos    1665          1975.          2781.
## 2 26 a 35 anos   3222          3594.          5630.
## 3 36 a 50 anos   5784          4726.          8189.
## 4 Mais de 50 anos 4867          4314.          7114.
```

Pode-se notar uma certa semelhança entre os grupos de 36 a 50 anos e mais de 50, apesar do grupo de 36 a 50 apresentar média e desvio padrão relativamente superiores.


```
#boxplot das faixas etarias (largura e altura ajustadas)
ate25 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "Até 25 anos"]


de26a35 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "26 a 35 anos"]

de36a50 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "36 a 50 anos"]

mais50 <- base_rj$variables$VD4020[base_rj$variables$grupo_idade == "Mais de 50 anos"]

boxplot(
  ate25,
  de26a35,
  de36a50,
  mais50,
  names = c("Até 25 anos", "26 a 35 anos", "36 a 50 anos", "50+ anos"),
  main = "Rendimento por Idade",
  ylab = "Rendimento"
)
```


Rendimento por Idade



No boxplot podemos ver que

os grupos de 36 a 50 e mais de 50 apresentam número de outliers parecido, sendo o grupo de 36 a 50 o que apresenta a observação de maior rendimento. Mais uma vez criei outro boxplot sem outliers para melhor análise.

```
#boxplot das faixas etarias sem outliers (altura e largura ajustadas)
boxplot(
  ate25,
  de26a35,
  de36a50,
  mais50,
  names = c("Até 25 anos", "26 a 35 anos", "36 a 50 anos", "50+ anos"),
  main = "Rendimento por Idade",
  ylab = "Rendimento",
  outline = FALSE
)
```



parecidas entre os 3 últimos grupos, sendo que o grupo de 36 a 50 anos apresenta mediana e dispersão um pouco maiores do que os outros dois. Além disso, é importante destacar o quão concentrado está o grupo de até 25 anos, seu terceiro quartil está em torno de R\$2.000,00, isso quer dizer que dentre as observações, 75% das pessoas com até 25 anos possuem renda de até R\$2.000,00.

```
#imprimindo a ANOVA
anova_idade <- aov(VD4020 ~ grupo_idade, data = base_rj$variables)

summary(anova_idade)
```

```
##              Df    Sum Sq  Mean Sq F value Pr(>F)
## grupo_idade    3 1.082e+10 3.606e+09   74.78 <2e-16 ***
## Residuals 15534 7.489e+11 4.821e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Foi realizada uma análise de variância (ANOVA) com o objetivo de verificar se existiam diferenças estatisticamente significativas entre os rendimentos médios dos grupos etários. O teste apresentou valor de F elevado e p-valor inferior a 0,05, indicando evidência suficiente para rejeitar a hipótese nula de igualdade entre as médias. Dessa forma, conclui-se que há diferença estatisticamente significativa entre os rendimentos médios dos grupos analisados. Esse resultado está em concordância com a análise descritiva e com os boxplots, que já indicavam diferenças entre os grupos, com destaque para o grupo de 36 a 50 anos, que apresentou maiores valores médios na análise descritiva.